Revista Eletrônica
Paulista de Matemática

ISSN 2316-9664
preprint

Análise dos Dados Oficiais de COVID-19 nos Municípios de Bauru e São Paulo Utilizando o Modelo SIR para os Anos Críticos da Pandemia (2020-2022)

Analysis of Official COVID-19 Data in the Municipalities of Bauru and São Paulo Using the SIR Model for the Critical Pandemic Years (2020-2022)

Eduardo Ferreira da Silva
Departamento de Ciências e Matemática do Campus de São Paulo (DCM-SPO)
Instituto Federal de Educação, Ciência e Tecnologia de São Paulo - Campus São Paulo (IFSP-SPO)
eduardo.ferreira2@aluno.ifsp.edu.br

Luciano Aparecido Magrini
Departamento de Ciências e Matemática do Campus de São Paulo (DCM-SPO)
Instituto Federal de Educação, Ciência e Tecnologia de São Paulo - Campus São Paulo (IFSP-SPO)
magrini@ifsp.edu.br

Resumo

Neste trabalho discute-se o uso do modelo epidemiológico suscetível-infectado-recuperado (SIR) no estudo da evolução da propagação da COVID-19 nos municípios de São Paulo e de Bauru durante os anos de 2020, 2021 e 2022. Através da busca dos parâmetros ótimos para o modelo utilizado fez-se uma análise dos dados reais da evolução da doença para os anos indicados. Investiga-se como o modelo SIR considerado se adequa aos dados oficiais da evolução da doença via simulações numéricas e discute-se a dinâmica da doença para os municípios escolhidos. Os nossos achados estão de acordo com os constantes avisos das autoridades sanitárias de que os dados da doença em nosso país foram subestimados e trazem elementos de como a dinâmica da doença se desenvolveu nas cidades consideradas neste estudo.

Palavras-chave: Equações Diferenciais Ordinárias. COVID-19. Simulações Numéricas. Epidemiologia.

Abstract

In this work, we discuss using the susceptible-infected-recovered (SIR) epidemiological model to study the evolution of COVID-19 spread in the municipalities of São Paulo and Bauru during 2020, 2021, and 2022 years. An analysis of real data on the disease's progression for the specified years was performed by optimizing the model parameters. The study investigates how the considered SIR model fits the official data on the disease's progression through numerical simulations and explores the dynamics of the disease in the selected municipalities. Our findings align with repeated warnings from health authorities that the disease data in our country were underestimated and provide insights into how the disease dynamics unfolded in the cities considered in this study.

Keywords: Ordinary Differential Equations. COVID-19. Numerical Simulations. Epidemiology.

1 Introdução

Ao longo dos séculos, diversas doenças infecciosas afligiram os seres humanos. Algumas delas infectaram conjuntamente um grande número de pessoas em uma determinada localidade por certo tempo, o que define uma epidemia. Porém, outras não se limitaram a uma determinada região e se espalharam ao redor do globo, o que estabelece uma pandemia.

Com isso, a história da humanidade foi impactada de maneira mais severa pelas epidemias e pandemias de doenças infecciosas com maior taxa de letalidade, as quais levaram a uma grande quantidade de óbitos e evidenciaram a necessidade da compreensão e previsão da propagação e do curso de doenças infecciosas, bem como da formulação de estratégias para mitigação de seus efeitos.

Nesse contexto, surgem a epidemiologia e, posteriormente, os modelos epidemiológicos, os quais são modelos matemáticos que tem por objetivo descrever, com relativa precisão, o curso da evolução temporal de uma doença por meio de equações diferenciais. Um dos modelos que trouxe grande contribuição para as teorias epidemiológicas matemáticas foram os modelos desenvolvidos na década de 1920 por William Kermack e Anderson McKendrick (KERMACK; MCKENDRICK, 1927) os modelos SIR (Suscetível-Infectado-Recuperado).

Utilizando esses modelos, métodos numéricos e o auxílio de computação é possível, por exemplo, simular a quantidade de pessoas susceptíveis a uma doença, infectadas por essa doença e recuperadas ou mortas por essa mesma doença, em função do tempo, tendo apenas as condições iniciais e o valor de alguns parâmetros relacionados ao curso dessa infecção em um determinado período.

Um dos exemplos mais palpitantes em que a epidemiologia matemática foi de extrema relevância e que doenças infecciosas atingiram diversos territórios foi a pandemia de COVID-19, causada pelo vírus SARS-CoV-2, o qual foi detectado no final de 2019 em Wuhan, na China, e rapidamente se espalhou por todo o mundo, resultando em mais de 775 milhões de casos e mais de 7 milhões de mortes globalmente (WHO, 2024). Dessa forma, este evento sublinhou a importância dos modelos epidemiológicos para a orientação de políticas de saúde pública no combate de epidemias e pandemias.

Isto posto, o presente artigo é uma expansão e aprofundamento do resumo apresentado na seção de pôsteres do VII Encontro Regional de Matemática Aplicada e Computacional, ERMAC Bauru 2024, (SILVA; MAGRINI, 2024), que aconteceu do dia 21 a 24 de maio de 2024, em Bauru, e no qual foi realizada uma análise dos dados oficiais da pandemia de COVID-19 correspondentes aos 60 primeiros dias do ano pandêmico de 2020 via modelo SIR.

Destarte, este trabalho tem como objetivo utilizar o modelo epidemiológico SIR para buscar os parâmetros ótimos que fazem os dados simulados se aproximarem mais dos dados oficiais e analisar a propagação da COVID-19 não apenas para o município de São Paulo, como também para o de Bauru, durante não apenas os 60 primeiros dias pandêmicos de 2020 como também os anos pandêmicos de 2020, 2021 e 2022, comparando os resultados obtidos com os dados oficiais. A escolha pelas cidades de São Paulo e Bauru deve-se ao fato de que, enquanto a primeira é a maior cidade do país, a segunda é a cidade em que o ERMAC aconteceu.

Na Seção (2), são apresentados os aspectos teóricos do modelo SIR, os detalhes relativos ao processo da integração numérica utilizada e a fundamentação do tratamento de dados utilizado nos dados brutos. Em seguida, na Seção (3), são discutidos os dados oficiais considerados, incluindo o processo de filtragem.

Na Seção (4) todas simulações numéricas realizadas via modelo SIR com os dados filtrados e as análises gráficas dos resultados obtidos. Posteriormente, na Seção (5) são apresentados os resultados numéricos dos parâmetros ótimos buscados e apresenta-se uma discussão sobre o que foi obtido.

Por fim, na Seção (6) são colocadas as conclusões das análises feitas nas seções anteriores, bem como a especulação de futuros trabalhos para aprofundação das discussões.

2 Fundamentação

Apresentam-se, nesta seção, a descrição do modelo epidemiológico considerado, uma breve exposição da integração numérica utilizada e uma descrição da filtragem de dados que foi utilizada.

2.1 Descrição do Modelo

Neste trabalho considera-se o modelo epidemiológico suscetível-infectado-recuperado (SIR) com as hipóteses assumidas em (FRANCO; DUTRA, 2021).

De modo resumido, no modelo SIR assume-se que um indivíduo está em um de três compartimentos populacionais em relação ao tempo. Assim, ele pode estar na parcela da população N (constante, por suposição): susceptível, $S(t)$, a qual pode contrair a doença; ou infectada, $I(t)$, a qual contraiu a doença; ou recuperada/removida, $R(t)$, a qual se recuperou da doença e adquiriu imunidade eterna ou veio a óbito. Com isso, a população pode ser descrita pela seguinte equação:

$$N = S(t) + I(t) + R(t) \tag{1}$$

Além disso, os parâmetros considerados no modelo são: a taxa de infecção (α), que determina a velocidade de propagação de uma doença; a taxa de recuperação (β), que determina a velocidade com que indivíduos infectados se recuperam da doença ou morrem antes de se recuperar; a taxa que a população suscetível está sendo transferida para a população infectada $\left(\frac{\alpha IS}{N}\right)$; e a taxa que a população infectada está sendo transferida para a população removida (βI). Visualmente, o modelo pode ser representado por:

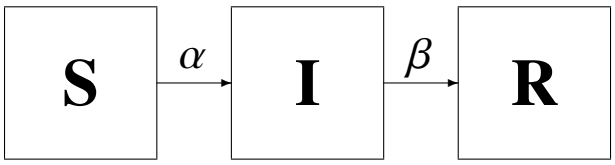

Figura 1: Representação do Modelo SIR em compartimentos.

Por conseguinte, obtém-se que as variações de $S(t)$, $I(t)$ e $R(t)$ podem ser descritas por equações diferencias ordinárias (EDOs) e o modelo SIR pode ser descrito pelo seguinte sistema não linear de

EDOs:

$$\begin{cases} \dfrac{dS}{dt} = \dfrac{-\alpha IS}{N} \\ \dfrac{dI}{dt} = \dfrac{\alpha IS}{N} - \beta I \\ \dfrac{dR}{dt} = \beta I \end{cases} \tag{2}$$

As condições iniciais do modelo no momento t_0 são definidas como: $S(t) = S_0$, $I(t) = I_0$ e $R(t) = R_0$; e nas simulações foi considerado razoável assumir $S(t) \approx N$, pois, segundo os autores (FRANCO; DUTRA, 2021) para uma população constante $S(t) \leq S_0$, o número de infectados $I(t)$ e o número de recuperados $R(t)$ é pequeno comparado com o número do total da população N. Desta maneira, o modelo descrito por (2) pode ser reescrito como:

$$\begin{cases} \dfrac{dS}{dt} = -\alpha I \\ \dfrac{dI}{dt} = \alpha I - \beta I \\ \dfrac{dR}{dt} = \beta I \end{cases} \tag{3}$$

2.2 Integração Numérica

Nas simulações numéricas realizadas neste artigo, optou-se pelo método de Runge-Kutta de quarta ordem (RK4) devido à sua alta precisão e custo computacional relativamente baixo na obtenção da solução numérica de um sistema de EDOs.

O método de RK4 é um método de integração numérica iterativo que busca aproximar a solução de problemas de valor inicial (PVI's) da forma:

$$y' = f(t, y), \quad y(t_0) = y_0, \tag{4}$$

em que $y \in \mathbb{R}^n$ e $f(t, y) \in \mathbb{R}^{n+1}$.

Uma maneira de avaliar a precisão de um método de integração numérica é pela ordem do erro de truncamento global (E_n) em relação ao tamanho do passo de integração (h), a qual indica a proporcionalidade da diferença entre a solução do problema de valor inicial (4) e sua aproximação numérica, considerando o tamanho do passo, ou seja, quanto maior ordem de E_n em relação a h, mais rapidamente a precisão do método aumentará com a diminuição do tamanho do passo.

Para o RK4, o E_n é da ordem de h^4, por esse motivo e pelo fato de possuir quatro estágios em cada passo, ele é chamado de método de quarta ordem. Em comparação com métodos de ordem inferior, como, por exemplo, o método de Euler, o qual possuí E_n da ordem de h, o RK4 oferece uma redução significativa no erro de truncamento global com passos de tamanho semelhante, sendo suficiente para os objetivos das simulações contidas neste trabalho.

Deste modo, pelo método de RK4, a aproximação de y_{n+1} no próximo ponto $t_{n+1} = t_n + h$ envolve uma média ponderada dos valores de $f(y, t)$ em diferentes pontos t no intervalo $t_n \leq t \leq t_n + h$ e é

dada por:

$$y_{n+1} = y_n + \frac{h}{6}\left(k_{n1} + 2k_{n2} + 2k_{n3} + k_{n4}\right), \tag{5}$$

no qual:

$$\begin{aligned} k_{n1} &= f(t_n, y_n), \\ k_{n2} &= f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}k_{n1}\right), \\ k_{n3} &= f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}k_{n2}\right), \\ k_{n4} &= f(t_n + h, y_n + hk_{n3}). \end{aligned}$$

Para maiores detalhes sobre a integração numérica com RK4 consulte (BOYCE; DIPRIMA, 2012).

2.3 Processamento de Dados e Análise de Séries Temporais

Dados são valores discretos, qualitativos ou quantitativos, que comunicam alguma informação. Quando eles descrevem uma certa variável sequencialmente em relação ao tempo são chamados de série temporal. Nela, é possível aplicar técnicas de análise de séries temporais a fim de ter uma importante ferramenta para análise de dados, como claramente exposto por Robert Shumway e David Stoffer em "*Time Series Analysis and Its Application*" (SHUMAY; STOFFER, 2011), e consequente simulação numérica com o resultado obtido.

Nesta subseção apresenta-se brevemente as funções utilizadas no tratamento numérico dos dados analisados. Dentre as possibilidades de funções para o tratamento de dados, descreve-se apenas as principais utilizadas neste trabalho. Para maiores detalhes, consulte a documentação da biblioteca de código aberto e escrita em linguagem de programação *Python*, *pandas*[1].

Algumas das funções da *pandas* utilizam as ferramentas de análise de séries temporais para grandes volumes de informação que representam séries temporais, como as relacionadas à evolução de casos de uma doença em um município ao longo do tempo, que é o caso dos dados da pandemia de COVID-19 ao longo de 2020, 2021 e 2022.

Duas das importantes funções da *pandas* são a "*.query*", a qual faz a filtragem de dados específicos por meio de uma expressão condicional e o "*.dt.year*", a qual extrai o componente ano de cada data, este devendo estar no formato correto utilizando, por exemplo, a função "*parse_dates*".

Nessa biblioteca, as funções "*.rolling(window=7)*" e "*.mean()*" combinadas, calculam a média móvel de 7 dias dos dados, uma técnica para suavizar séries temporais e eliminar flutuações de curto prazo. A média móvel pode ser matematicamente expressa como:

$$\mathrm{MM}_7(t) = \frac{1}{7}\sum_{i=0}^{6} x_{t-i}\,, \tag{6}$$

na qual x_{t-i} representa o valor do dado no dia $t - i$ e $\mathrm{MM}_7(t)$ é a média móvel de 7 dias para o dia t.

Além disso, existem outras duas funções úteis, "*.head()*", a qual é utilizada para extrair as primeiras linhas de um DataFrame, e "*.fillna(method='bfill')*", a qual emprega o método "*Back Fill*" para selecionar o próximo valor válido e preencher os dados do tipo *NaN* (*Not a Number*) anteriores.

[1] Acesse em: https://pandas.pydata.org/docs/

3 Dados

Considerou-se os dado oficiais da Fundação SEADE - Sistema Estadual de Análise de Dados relativos ao total da população e à evolução do número de casos confirmados de COVID-19 para os municípios de São Paulo e Bauru, desde as datas de registro dos primeiros casos, 26/02/2020 em São Paulo e 03/04/2020 em Bauru, até 31/12/2022, período em que os casos de COVID-19 mostraram tendência à estabilidade (SEADE, 2023).

Para mais informações, os dados brutos, os dados filtrados e os códigos para filtragem encontram-se no repositório do *GitHub*[2].

3.1 Filtragem dos Dados

A filtragem de dados foi realizada em linguagem *Python* utilizando a biblioteca *pandas*, já descrita na Subseção (2.3).

Inicialmente a função "*.query*" foi utilizada para selecionar apenas os dados dos casos confirmados de COVID-19 referentes ao município de Bauru e, em seguida, apenas os dados do município de São Paulo.

Após esta etapa, fez-se a filtragem dos anos pandêmicos de 2020, 2021 e 2022 para cada um dos municípios utilizando as funções "*parse_dates*", para converter as datas ao formato adequado, e "*.dt.year*", para extrair a componente do ano de cada data. Dessa forma, foi possível aplicar uma expressão condicional para selecionar os anos de interesse.

Na sequência as funções "*.rolling(window=7).mean()*"foram utilizadas para calcular a média móvel, "*.fillna(method='bfill')*", para preencher os valores NaN gerados nos primeiros 6 dias de cada ano, nos quais não foi possível calcular a média móvel, e "*.head(60)*, para selecionar os 60 primeiros dias pandêmicos de 2020 no município de São Paulo.

Como última etapa fez-se uso de uma expressão condicional para remover os valores zero dos dados e, em seguida, subtraíram-se os casos acumulados de 2020 dos dados de 2021 e, também, os casos acumulados de 2020 e 2021 dos dados de 2022 para cada município. Dessa maneira, conseguiu-se analisar apenas os casos referentes a cada ano específico.

3.2 Análise dos Dados Oficiais

A população dos municípios de São Paulo e Bauru permaneceu constante entre 2020 e 2022, com 11869660 habitantes em São Paulo e 364225 habitantes em Bauru. Até 2022, o número acumulado de casos de COVID-19 foi de 1139273 em São Paulo e 86544 em Bauru, o que representa aproximadamente 9,6% e 23,76% da população total já tendo sido infectada pela doença, respectivamente. Esses dados indicam que Bauru foi proporcionalmente mais impactado pela doença, possivelmente devido a fatores locais, como a resposta do sistema de saúde e as medidas de controle adotadas.

Na Figura (2), observa-se os dados tratados referentes aos municípios de São Paulo e Bauru e que em ambos os municípios, 2021 foi o ano no qual registrou-se mais casos de COVID-19, sendo o período mais crítico da pandemia no período analisado.

A curva do município de São Paulo em 2020 parece apresentar uma tendência exponencial mais acentuada em comparação a de Bauru, o que pode indicar uma propagação mais rápida do vírus na capital nesse primeiro ano da pandemia. Contudo, nos anos seguintes, essa relação se inverte,

[2] Acesse em: https://github.com/Edufsx/covid-19-data-processing-and-rk4-numerical-simulations/blob/main/code/covid19_data_filtering.py

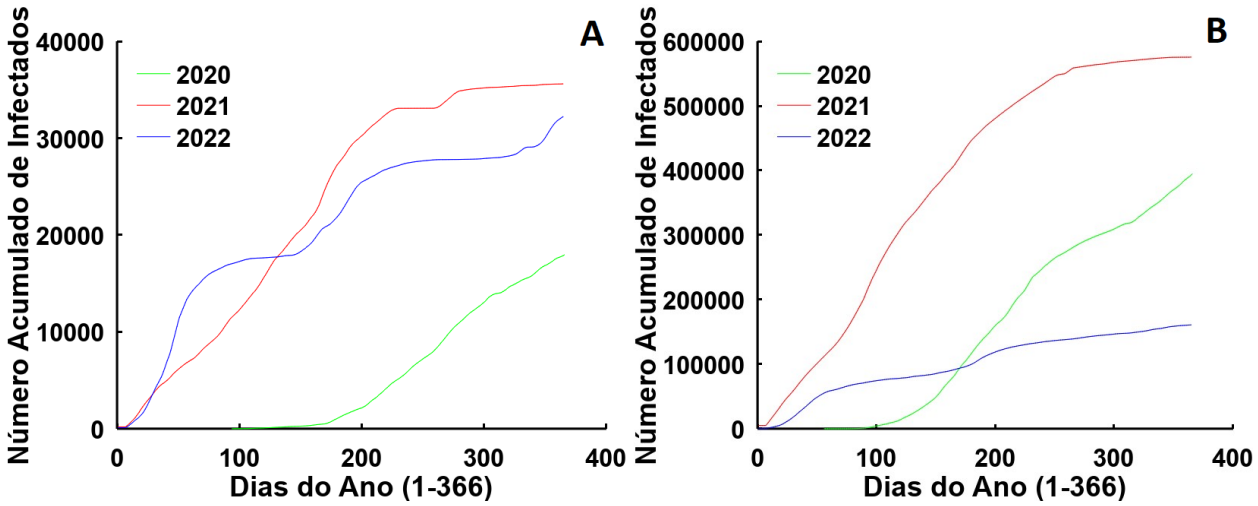

Figura 2: Número Acumulado Oficial de Infectados por COVID-19 pelo tempo, em dias, nos anos de 2020, 2021 e 2022, isoladamente, para os municípios de Bauru (A) e de São Paulo (B). Fonte: Os autores.

possivelmente devido aos casos de COVID-19 terem chegado em Bauru 38 dias mais tarde do que em São Paulo, o que também pode ter impactado na diferença do comportamento das curvas nos anos subsequentes comparando os dois gráficos.

As curvas dos municípios de São Paulo e Bauru apresentam uma tendência crescente ao longo dos três anos analisados. No entanto, nota-se uma tendência à estabilização da curva de São Paulo em 2022, especialmente após o final de 2021, motivo pelo qual escolheu-se 2022 como sendo o ano final das simulações.

Além disso, essa análise dos gráficos sugere que a vacinação contra a COVID-19 no estado de São Paulo, a qual foi introduzida em janeiro de 2021 e avançou gradualmente conforme prioridade dos grupos de risco, contribuiu de forma significativa para essa estabilização observada no final de 2021 para os dois gráficos e ao longo de 2022 para o município de São Paulo.

4 Simulações Numéricas

As simulações numéricas foram realizadas em *Python*, utilizando o método RK4 para a integração de (3) e com o intuito de buscar qual o par de parâmetros ótimos α e β e qual valor de I_0 que faria o número de infectados simulado se aproximar mais do número de infectados oficial (SEADE,2023). Essa proximidade foi determinada pelo erro quadrático acumulado (EQA), que pode ser descrito pela seguinte fórmula:

$$EQA = \sum_{t=0}^{n} (Y_t - p_t)^2 , \tag{7}$$

na qual n é número de dados analisados e no caso deste trabalho, Y_t é o número de infectados simulado no tempo t e p_t é o número de infectados oficial no tempo t. O passo de integração foi de $h = 10^{-3}$ e a discretização do intervalo dos parâmetros α e β foi de $\Delta = 10^{-3}$ para todas as simulações realizadas.

Inicialmente, fez-se a busca dos parâmetros ótimos α e β no intervalo [0.5, 0.95], na primeira simulação, e [0.3, 0.7], em todas as outras simulações, que minimizassem o EQA, e logo após,

com os resultados obtidos variou-se o número inicial de infectados I_0 buscando o I_0 ótimo que minimizasse EQA observado nessa simulação inicial.

Na sequência, descrevem-se as condições iniciais para cada simulação numérica realizada, nas quais I_0 é o número de casos oficias de COVID-19 novos no primeiro dia considerado da simulação, R_0 é o número de recuperados ou mortos pela doença (considerando-se que recuperados ou mortos são o total de casos acumulados até 31 de dezembro do ano anterior), e S_0 foi obtido através de (1).

As simulações foram realizadas conforme descrito a seguir:

- Primeira simulação: considerou-se os dados filtrados do município de São Paulo dos 60 primeiros dias da pandemia de COVID-19 (26/02/2020 à 26/04/2020), com intervalo de integração [0,60] e condições iniciais $S_0 = 11869559$, $I_0 = 1$ e $R_0 = 0$;
- Segunda Simulação: considerou-se os dados filtrados do município de São Paulo do ano pandêmico de 2020, portanto mesmas condições iniciais anteriores e com intervalo de integração de $[0, 310]$;
- Terceira Simulação: considerou-se os dados filtrados do município de Bauru do ano pandêmico de 2020, com intervalo de integração $[0, 273]$ e condições iniciais $S_0 = 364223$, $I_0 = 2$ e $R_0 = 0$.

Nas simulações subsequentes, o intervalo de integração foi de [0, 365]:

- Quarta simulação: considerou-se os dados filtrados do município de São Paulo do ano pandêmico de 2021 e condições iniciais $S_0 = 11466825$, $I_0 = 1117$ e $R_0 = 401718$;
- Quinta simulação: considerou-se os dados filtrados do município de Bauru do ano pandêmico de 2021 e condições iniciais $S_0 = 345928$, $I_0 = 8$ e $R_0 = 18289$;
- Sexta Simulação: considerou-se os dados filtrados do município de São Paulo do ano pandêmico de 2022 e condições iniciais $S_0 = 10891674$, $I_0 = 68$ e $R_0 = 977918$;
- Sétima Simulação: considerou-se os dados filtrados do município de Bauru do ano pandêmico de 2022 e condições iniciais $S_0 = 310282$, $I_0 = 1$ e $R_0 = 53942$.

Para informações adicionais, os códigos utilizados para nas simulações encontram-se no repositório do *GitHub*[3].

Os parâmetros ótimos α e β obtidos foram utilizados para a construção das Figuras (3), (4) e (5), e serão apresentados na Seção (5).

A Figura (3) apresenta os principais resultados das simulações realizadas, comparando os dados simulados de cada ano em gráficos que possuem ambos os eixos na escala logarítmica, utilizada para melhor visualização.

A análise dos dados simulados sugere que 2021 foi o ano mais crítico da pandemia em ambos os municípios, com 2022 sendo o segundo ano com mais casos em Bauru. Esses resultados apontam na mesma direção que os dados oficiais, indicando que o modelo SIR possui uma previsibilidade relativamente boa. No entanto, o modelo não conseguiu descrever adequadamente o comportamento do ano de 2022 para o município de São Paulo, no qual, segundo os dados oficiais, havia uma tendência de estabilização.

[3] Acesse em: https://github.com/Edufsx/covid-19-data-processing-and-rk4-numerical-simulations/blob/main/code/numerical_simulation_parameter_search_plot.py

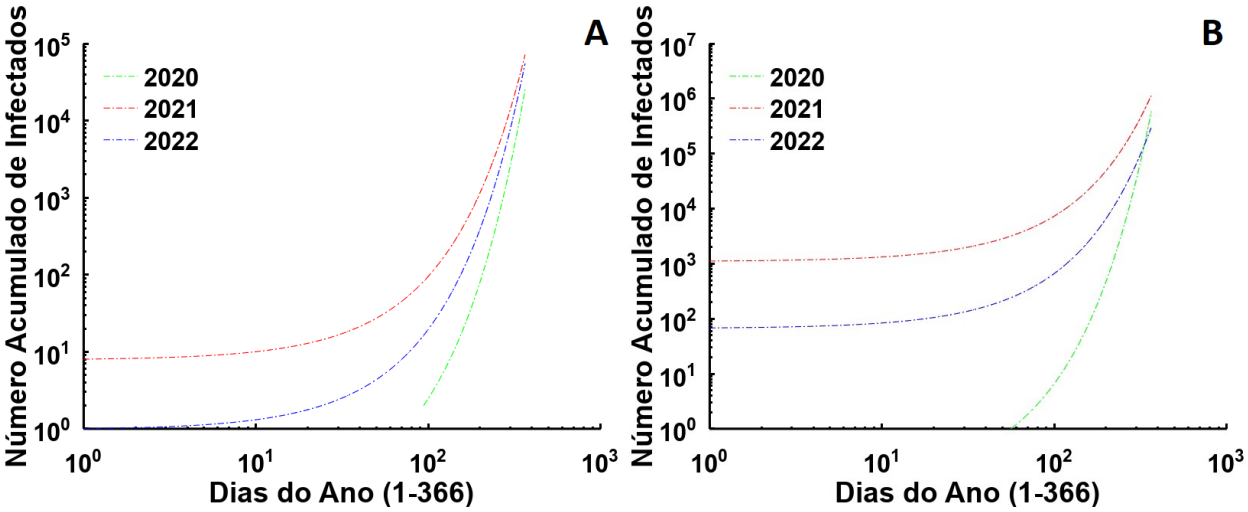

Figura 3: Número Acumulado Simulado de Infectados por COVID-19 pelo tempo, em dias, nos anos de 2020, 2021 e 2022, isoladamente, para os municípios de Bauru (A) e de São Paulo (B). Fonte: Os autores.

Como o modelo SIR não leva em consideração o impacto da vacinação na dinâmica da COVID-19, não é possível inferir a influência da introdução da vacinação em 2021 sobre o comportamento da doença apenas com base na análise dos dados simulados. Além disso, a simulação para 2022 mostrou um número menor de casos em comparação com 2021. Esse resultado pode ser atribuído à quantidade inicial de infectados, mas sugere que um menor número de casos registrados pode reduzir o espalhamento da doença.

A Figura (4) exibe o número acumulado de infectados, o número inicial de infectados e a simulação correspondente para os 60 primeiros dias do ano pandêmico de 2020 no município de São Paulo. Este resultado foi apresentado no ERMAC Bauru 2024 (SILVA; MAGRINI, 2024).

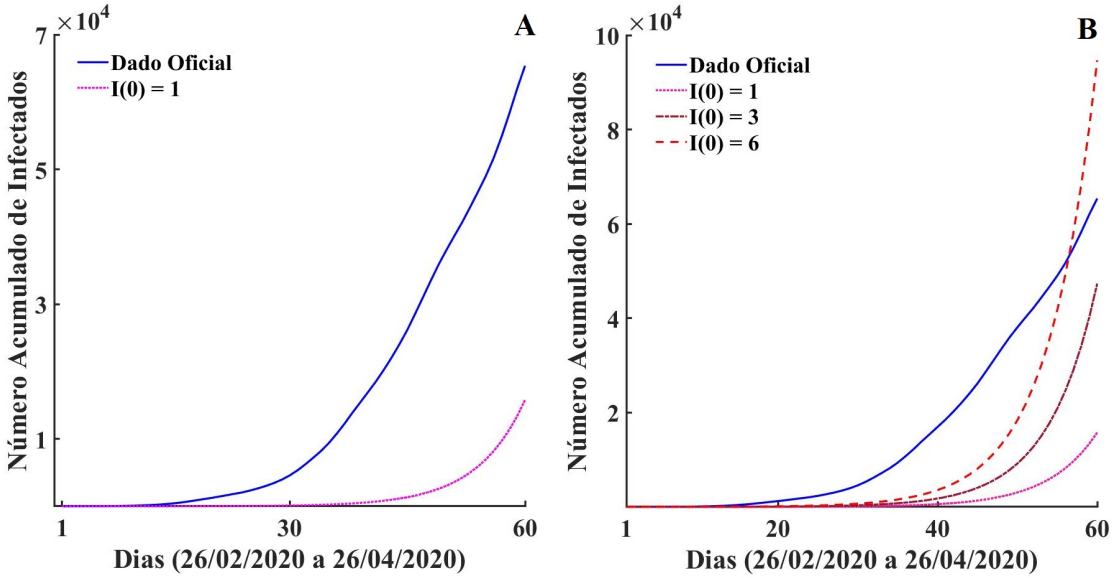

Figura 4: Simulações Numéricas para o Número de Infectados por COVID-19 no Município de São Paulo via Modelo SIR (3): (A) $I_0 = 1$ e (B) $I_0 = 1, 3$ e 6. Fonte: Os autores.

Analisando a Figura (4), é possível notar que a curva que representa o dado oficial se assemelha bastante ao comportamento de uma curva exponencial, o que mostra o quão acentuado foi a evolução da doença nesse período.

Pelos gráficos, é perceptível que a curva que representa $I_0 = 6$ se aproxima mais da curva que contém os dados oficias do que as outras, o que sugere haver, no momento inicial da pandemia, um número maior de infectados do que o indicado pelos dados oficiais. Esta observação está de acordo com a baixa taxa de testagem da população brasileira durante o período da pandemia.

A Figura (5) mostra os resultados obtidos da segunda até a sétima simulação na comparação das curvas obtidas com os dados oficiais e com os dados simulados.

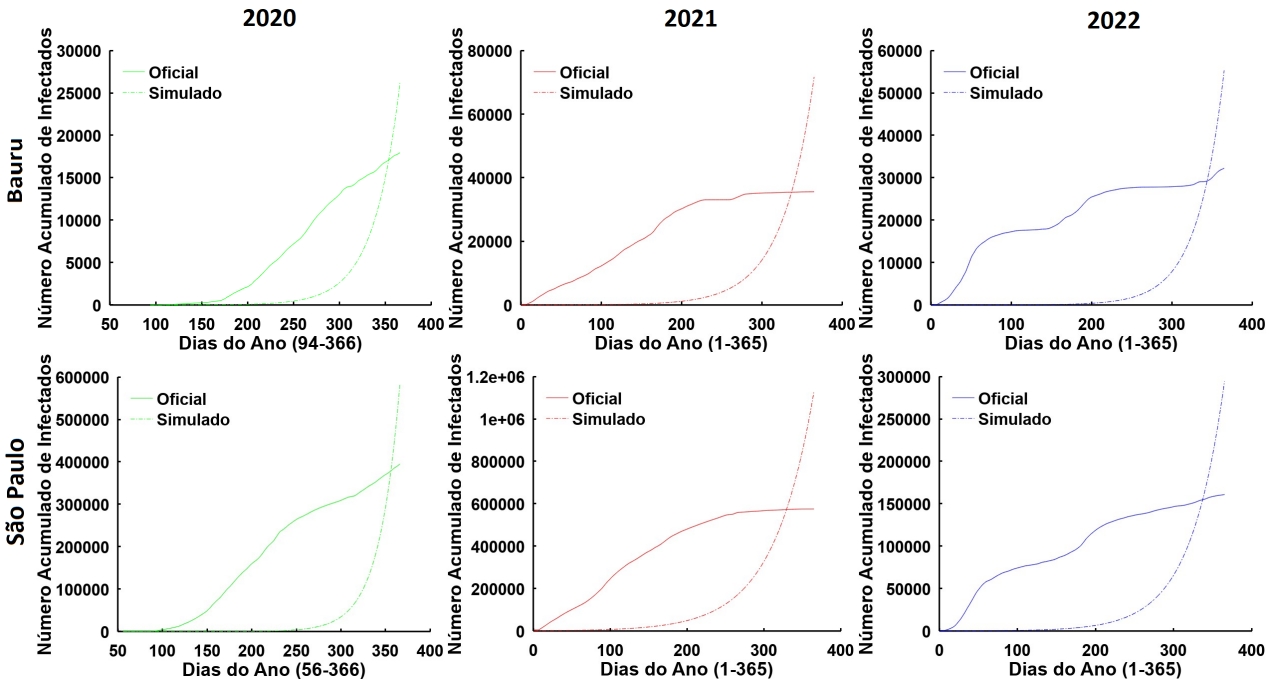

Figura 5: Comparação do número Acumulado Oficial e Simulado de Infectados por COVID-19 pelo tempo, nos anos de 2020, 2021 e 2022 para os municípios de Bauru (primeira linha) e São Paulo (segunda linha). Fonte: Os autores.

Em todos os gráficos constata-se que depois do momento inicial, o modelo prevê menos casos que os dados oficiais registram e após as curvas se intersectarem, o modelo prevê bem mais casos que os dados oficiais. Isto era previsível pois o modelo SIR considerado apresenta comportamento exponencial de modo que, sua taxa de crescimento é a maior dentre todas as outras funções reais.

Ao analisar todos os painéis da Figura (5), observa-se que os dados simulados diferem dos dados oficiais em ambos os municípios. Essa diferença ocorre principalmente porque o sistema que representa o modelo SIR utilizado como base, o sistema (3), possui uma solução exponencial. Além do mais, previsões feitas por modelos epidemiológicos em períodos longos tendem a se desviar significativamente da realidade, devido ao número limitado de variáveis consideradas, em contraste com a complexidade real dos fatores envolvidos.

Apesar disso, no ano pandêmico de 2020, os dados oficiais dos municípios de Bauru e São Paulo exibiram um comportamento semelhante ao de uma curva exponencial. Como os dados simulados pelo modelo SIR escolhido também seguem um padrão exponencial, isso mostra que o modelo pode representar bem os períodos mais agressivos da evolução da COVID-19 apesar de sua simplicidade.

Ademais, pela diferença entre as escalas da Figura (5) e da Figura (2), percebe-se que as curvas dos dados oficiais de 2021 e 2022, em ambos os municípios, apresentam uma tendência de estabilização depois, aproximadamente, do dia 200. Essa estabilização é mais acentuada no final de 2021 e um pouco menos em 2022. Isso ocorre porque ao compará-las com uma curva exponencial as diferenças nas taxas de crescimento entre os períodos ficam mais evidente.

5 Resultados e Discussão

Nesta seção, apresentama-se as tabelas com os resultados das simulações realizadas utilizando o modelo SIR, destacando os parâmetros ótimos α, β e I_0, que minimizam o EQA no período analisado. Além disso, apresenta-se o valor oficial de I_0 para cada ano e comparam-se os valores do EQA I_0 oficial e I_0 ótimo. Por fim, analisam-se e discute-se os resultados obtidos.

5.1 Município de São Paulo

A Tabela (1) apresenta os resultados da primeira simulação, enquanto a Tabela (2) mostra os resultados da segunda, quarta e sexta simulação.

Parâmetros	**São Paulo - 2020 (60 dias)**
I_0 **Oficial**	1
α **Ótimo**	0.665
β **Ótimo**	0.501
Ordem EQA I_0 **Oficial**	10^{10}
I_0 **Ótimo**	6
Ordem EQA I_0 **Ótimo**	10^{9}

Tabela 1: Parâmetros relacionados aos resultados obtidos da simulação dos 60 dias iniciais do ano pandêmico de 2020 no município de São Paulo, via modelo SIR. Fonte: os autores.

Parâmetros	**São Paulo - 2020**	**São Paulo - 2021**	**São Paulo - 2022**
I_0 **Oficial**	1	1117	68
α **Ótimo**	0.584	0.541	0.542
β **Ótimo**	0.541	0.522	0.518
EQA I_0 **Oficial**	$9.204516 \cdot 10^{12}$	$3.345500 \cdot 10^{13}$	$2.449725 \cdot 10^{12}$
I_0 **Ótimo**	1	1105	70
EQA I_0 **Ótimo**	$9.204516 \cdot 10^{12}$	$3.345109 \cdot 10^{13}$	$2.448721 \cdot 10^{12}$

Tabela 2: Parâmetros relacionados aos resultados obtidos da simulação dos anos pandêmicos de 2020, 2021 e 2022 no município de São Paulo, via modelo SIR. Fonte: os autores.

A taxa de infecção ótima apresentada na Tabela (1) foi bem alta se comparada com as taxas de infecção obtidas na Tabela (2) e isso sugere que o período inicial de 60 dias foi o período mais infeccioso da doença.

Na Tabela (1), pode-se observar que utilizando o I_0 ótimo nas simulações a ordem de grandeza do EQA cai 10 vezes em comparação com a utilização do I_0 oficial. Isso sugere, como já notado na

análise gráfica, que o registro oficial do número de infectados na data do primeiro registro de casos no município de São Paulo é subestimado.

Todavia, na busca pelo I_0 ótimo em todo o ano pandêmico de 2020 nota-se um resultado diferente: o I_0 obtido foi o mesmo que o I_0 oficial. Essa divergência pode ser explicada pelo fato de que modelos epidemiológicos são mais eficientes em previsões de curto prazo.

Na comparação do I_0 ótimo com o I_0 oficial, o de 2020 permaneceu o mesmo e os de 2021 e 2022 tiveram uma alteração, o que pode sugerir que nesses anos ocorreu uma pequena superestimação de casos de COVID-19 devido ao represamento no registro de dados nas semanas dos feriados de natal e ano novo.

Nas análises gráficas anteriores percebe-se que 2021 foi o ano mais crítico da pandemia. Porém, ao observar o resultado numérico exposto na Tabela (2) nota-se que o ano de 2020 apresentou a maior taxa de infecção, e não 2021. Isso indica que o número inicial de infectados (segundo o modelo considerado) parece ser mais determinante na evolução temporal dos infectados do que a taxa de infecção. Assim sendo, o ano de 2021 ser o mais crítico pode ser explicado pela grande quantidade de casos no começo do ano.

Ainda na Tabela (2) percebe-se que a taxa de infecção caiu de 2020 para 2021 e permaneceu praticamente a mesma de 2021 para 2022 e a taxa de recuperação apresenta tendência de queda ao longo dos três anos, o que pode representar uma menor circulação e e menor capacidade de transmissão do vírus com a introdução de vacinas além do adicional ganho de imunidade da população.

5.2 Município de Bauru

A Tabela (3) exibe os resultados da terceira, quinta e sétima simulação e são relativas à cidade de Bauru.

Parâmetros	**Bauru - 2020**	**Bauru - 2021**	**Bauru - 2022**
I_0 **Oficial**	2	8	1
α **Ótimo**	0.576	0.541	0.360
β **Ótimo**	0.541	0.516	0.330
Ordem EQA I_0 **Oficial**	10^9	10^{11}	10^{11}
I_0 **Ótimo**	2	8	1
Ordem EQA I_0 **Ótimo**	10^9	10^{11}	10^{11}

Tabela 3: Parâmetros relacionados aos resultados obtidos da simulação dos anos pandêmicos de 2020, 2021 e 2022 no município de Bauru, via modelo SIR. Fonte: os autores.

Analisando os resultados numéricos apresentados na Tabela (3), é possível identificar que taxa de infecção do município de Bauru caiu do ano pandêmico de 2020 para o de 2021, de forma semelhante com o ocorrido no município de São Paulo. Mas, diferente de São Paulo, de 2021 para 2022 a taxa de infecção caiu de forma expressiva, sugerindo que a vacinação em 2021 contribuiu de forma significativa para a redução da taxa de infecção no município de Bauru, gerando uma menor circulação do vírus e consequente redução expressiva da taxa de recuperação, já que teriam menos pessoas infectadas.

Essa mudança ser mais pronunciada em Bauru do que em São Paulo pode refletir uma resposta mais efetiva à pandemia, possivelmente devido a um menor número de habitantes e, portanto, a uma implementação mais eficaz das estratégias de vacinação e controle de infecções.

O ano pandêmico de 2021, segundo as análises gráficas, também foi o mais crítico da pandemia de COVID-19 no município de Bauru. Porém, na análise dos resultados numéricos 2021 não é o ano com a maior taxa de infecção, e sim, o ano com o mais número inicial de infectados. Fatos que corroboram para argumentação estabelecida na Subseção (5.1) de que o número de casos inicial é mais relevante, em uma perspectiva matemática, do que a taxa de infecção para a simulação do comportamento da doença via modelo SIR.

Dentre todas as simulações, a simulação via modelo SIR de 2020 no município de Bauru foi aquela que apresentou menor ordem do EQA, mostrando como os dados oficiais assemelham-se ao comportamento de uma curva exponencial.

Destaca-se ainda que o modelo SIR considerado adequa-se melhor aos dados de Bauru devido principalmente à menor complexidade das dinâmicas de movimentação/locomoção da população quando comparadas com as mesmas dinâmicas para a cidade de São Paulo.

6 Conclusões e Trabalhos Futuros

Apesar da simplicidade do modelo epidemiológico SIR (suscetível-infectado-recuperado) considerado neste trabalho foi possível investigar a dinâmica da epidemia de COVID-19 para as cidades de São Paulo e de Bauru. As simulações numéricas realizadas corroboram os alertas das autoridades sanitárias sobre a pouca testagem e subestimação dos dados oficiais da pandemia no Brasil e permitem concluir que, para intervalos de tempo relativamente curtos (como o de sessenta dias iniciais da pandemia), as simulações numéricas descrevem com boa acurácia a geometria da evolução temporal da doença ainda que em populações tão distintas como as das cidades de São Paulo e de Bauru. Como trabalhos futuros indica-se a investigação dos mesmos dados considerando modelos mais elaborados e que considerem a vacinação.

Agradecimento

Os autores agradecem à Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP) pelo fomento (Processo 2023/06097-8).

7 Referencias Bibliográficas

BOYCE, W. E.; DIPRIMA, R. C. **Equações Diferenciais Elementares e Problemas de Valores de Contorno**. 10. ed. Rio de Janeiro: LTC, 2012.

FRANCO, C. M. R.; DUTRA, R. F. **SIR model for propagation of COVID-19 in the Paraíba's State (Brazil)**. *Intermaths*, v. 2, n. 2, p. 39-48, 2021.

KERMACK, W. O.; MCKENDRICK, A. G. **A contribution to the mathematical theory of epidemics**. **Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character**, v. 115, n. 772, p. 700-721, 1927.

SEADE - Fundação Sistema Estadual de Análise de Dados. **Banco de Dados de Informações dos Municípios Paulistas**. São Paulo: 2023. Disponível em: https://www.seade.gov.br/coronavirus. Acesso em: 21 mar. 2024.

SHUMWAY, Robert H.; STOFFER, David S. **Time Series Analysis and Its Applications: With R Examples**. 3. ed. Nova York: Springer, 2011.

SILVA, Eduardo Ferreira da; MAGRINI, Luciano Aparecido. **Análise dos dados oficiais da pandemia de COVID-19 no município de São Paulo via modelo SIR**. Caderno de trabalhos completos e resumos do VII ERMAC – Encontro Regional de Matemática Aplicada e Computacional - Unesp, Bauru, p. 253-254, 2024.

WHO - World Health Organization. **WHO Coronavirus (COVID-19) dashboard**. Genebra: WHO, 2023. Disponível em: https://data.who.int/dashboards/covid19. Acesso em: 12 ago. 2024.